

修士論文

深層学習を用いた固気液三相流の 超音波計測

37246227 松原貞徳

指導教員 高木周教授

2026 年 1 月

目次

第 1 章	序論	7
1.1	研究背景	7
1.2	関連研究	8
1.2.1	エアリフトポンプを用いた揚降実験に関する研究	8
1.2.2	混相流計測手法に関する研究	8
1.2.3	その他の研究	10
1.3	研究目的	11
1.3.1	本論文の構成	11
第 2 章	技術的背景	13
2.1	超音波計測	13
2.2	音響信号処理	13
2.2.1	数理変換	14
2.2.2	超音波画像法	14
2.2.3	ノイズ除去	14
2.3	数値計算手法	15
2.3.1	計算原理	15
2.3.2	疑似スペクトル法 (pseudospectral method)	16
2.3.3	安定性解析	16
2.4	機械学習	16
2.4.1	正規化・正則化	17
2.4.2	モデルの種類と概要	17
2.4.3	モデル解釈	18
2.4.4	ベイズ最適化	19
第 3 章	実験手法・実験系	21

4 目次

3.1	実験装置・計測機器	21
3.2	実験条件・手順	22
3.3	データ取得方法	23
第4章 計算系		25
4.1	計算系の設計	25
4.1.1	グリッドサイズ	25
4.1.2	固液二層流	26
4.1.3	気液二層流(未実施)	27
4.2	数値計算結果	28
4.2.1	液相のみ	28
4.2.2	固液二層	31
第5章 提案手法		33
5.1	制約条件	34
5.2	手法	34
5.2.1	指標	34
5.2.2	固液二層に対する手法	34
5.2.3	固気液三相流に対する手法	36
第6章 学習結果		37
6.1	固液二層流	37
6.1.1	課題	38
6.1.2	問題解決の提案	39
6.2	固気液三相流	39
6.2.1	課題	40
6.2.2	問題解決の提案	41
6.3	考察	41
6.3.1	判断メカニズムの考察	41
6.3.2	管径に依存しないモデルの構築	41
第7章 結論		43
謝辞		44
参考文献		45

付録 A	付録	48
A.1	指標	48
A.2	物性値	49

第1章

序論

1.1 研究背景

数々の調査により、海底には豊富な海底資源が存在することが知られている。[1] 日本近海の海底資源を掘削、開発する研究は長年続けられてきたが、経済的な理由で実用に足る運搬手法は開発されていなかった。しかし近年では、メンテナンスが容易かつ運搬の仕組みが簡素であるとの理由でエアリフトポンプという機構が注目を集めている。この手法は海底に管をたてかけて、管内下部に資源と海水の混合流を流し込み、それらに圧縮空気を注入し空気が混合流と共に上昇しようとする力をを利用して運搬を行うというものである。当該手法の技術的課題としては、注入する空気の量を制御する必要があるというものが挙げられる。注入する空気量が多く、従来の流動様式マップにおいて環状流だと考えられる領域においても大きく揚鉱性能が下がる分けではないことが示唆されているものの、振動抑制などの観点から効率的な運搬のためにはこれらの注入量を適切に制御する必要がある。[2] また、システムを提案する上では系の構成方程式による性能の見積りが重要であるが、従来の気液二層モデルリングの式が本当に適切なのかを検証する必要がある。[3] しかし、エアリフトの系においても適用可能な技術は現在開発されていない。運搬する流体は不透明流体であるとの理由から、従来支配的であった光や γ 線を利用する方法は使用できず、また、鉱石を運搬する都合上、管にプローブを挿入するような侵襲的な計測手法は好まれない。

そこで注目されているのが超音波計測である。超音波はその反射波を測定し情報を利用することで不透明流体に対しても測定が行えると期待されており、また、流れに対して与える影響も無視できるほどに微弱である。海洋技術研究所で行われた実験データの提供を受け、計測された信号波形データと相体積率の間の関係性を解明し新たな計測技術の開発を行うことが期待されており、本研究室ではその協力を受けて技術開発を行った。

1.2 関連研究

エアリフトポンプを用い海底資源を揚降するプロジェクトが進行中であり、本研究室では超音波計測による物理量の測定技術の開発が期待されている。より詳しく言えば、実海域において最適な管径や空気吹き込み条件を取得できればシステム設計にとって非常に望ましく、そのための構成方程式の精度検証により実測値を必要としている。ゆえに、とくに超音波により相体積率を推定する技術開発が重要となっている。超音波を用いた流体計測技術は決して盛んであるとは言い難いがいくつかもの研究が行われてきた。

それらに対するアプローチを大別するものとして、純粹な物理的考察を重ねていくことによって予測を行うもの、データ駆動の手法によって予測を行うものが存在する。研究の概要を端的に示すために、まずエアリフトポンプの揚降実験に関する研究をまとめ、その後に混相流計測における研究を紹介することにする。

1.2.1 エアリフトポンプを用いた揚降実験に関する研究

2022年には、産業技術総合研究所の設備を利用して、本研究室の高木教授らによって200m 縦型水槽を用いた水一空気系及び泥水・空気系によるエアリフト実験が行われた。そこで、1990年代のマンガン団塊採鉱プロジェクトにおいて取得されたデータを良好に再現することを確認し、また、注入する空気量によらずロバストな揚水が行えることを示した。今後の展望として、管の中の流動状態を超音波により把握すること目的としていることが述べられている。

1.2.2 混相流計測手法に関する研究

流体計測技術を開発する研究は多岐にわたる。一般的なものとして、以下のようなものが挙げられる。・写真計測

- ・締め切り法
- ・PIV, PTV
- ・電気プローブ、光ファイバプローブ、ワイヤメッシュなど
- ・X線・ γ 線
- ・静電容量方式

本稿においては、機械学習あるいは超音波及びそれに準ずる手法に焦点をあてて解説を行うこととする。例えば、写真計測、PIV・PTV、ワイヤメッシュを用いた手法は流体工学上重要であるが、エアリフトへの応用可能性に乏しいので一部にとどめることとする。

電磁波を用いて気液二層流における流動様式を分類する研究は、直近のものでは[4]がみられる。ここでは、空気と水の透明な流体にワイヤメッシュを通して計測波形を取得しこれ

らを深層学習で処理することによって結果を得るといった手法を採用している。これらは、研究機関でデータセットの共有が行われており、それらを利用して流動様式の分類を行う機械学習モデルを訓練・評価している。例えば H Z D R というデータセットはヘルムホルツーゼントラム ドレスデンルーゼンドルフ研究機関で、T U D はドレスデン工科大学で取得されたものを示し、これらを用いて識別における汎化性能が示されている。

他にも、[5] では、 γ 線を利用した計測データをニューラルネットによって処理し、相の幾何学的配置と相体積率を高い精度で予測した研究がある。このデータは、北海の原油の転送パイプラインにおいて、油、水、ガスの含有率を非侵襲的に測定する技術を開発するために人工的に生成されたデータであり、実機のものではないことに注意が必要であるが、混相流の測定データを機械学習で処理する点が革新的であった。これらの研究を皮切りに、従来の物理学的アプローチに加え機械学習による推定が様々な研究者によって始められた。例えば、[6] では、 γ 線計測データを機械学習で処理することによって、相対誤差 5% 以内で相体積率の予測に成功した。しかし、これもシミュレーションにすぎず実機による検証が必要である。以降、超音波を用いた研究に焦点をあてて紹介する。超音波を用いた手法と電磁波を用いた手法は強度の取り扱いといった点において類似点が多いが、決定的な違いとしては、超音波は空気を通り抜けることが出来ず全反射するということである。しかし、それらを克服して予測を試みた研究が数多く存在する。[7] では、超音波計測において 4 つのトランスデューサからの信号を用いてニューラルネットを訓練することにより気相体積率を高い精度で予測することに成功した。また、同一人物であるが 2020 年において [8] では、超音波計測において 1 つのトランスデューサからの信号を用いて気液二層流の気泡流、スラグ流、チャーン流の 3 種の流動パターンを 97.9 % の精度で識別することに成功した。なお、この研究と類似するものが 2024 年に本研究室の尾花によって行われており、これらのコードを一部改良することによってスラグ、チャーンの 2 様式の分類ではあるが 90 % の精度で識別に成功している。流動様式の分類が高精度で行えることが示されたため、流動様式ごとの経験式・実験式のようなものがあればそれらを統合して予測することが可能だと考えられるが、超音波画像に基づく量での実験式は存在せず解決には至らなかった。なお、これらにおいては管径への汎化性能を得る手法についての議論は成されていない。

なお、統計的解法に頼らず純粹に物理的な手法も存在する。例えば、[9] では、気泡の形状に関する適切な仮定を行うことによりモデル化を行い、注入した気泡の体積率を相対誤差 30 % の精度で推定することに成功した。このアプローチとしては、反射強度及びドップラー効果を利用して気泡の位置と速度の推定を行い、統計的な仮定を行うことによって予測するといったものであった。しかし、これらは極めて微量な体積における推定結果であり、実運用の際の 40~80 % の体積率を推定することには適用できない。

エアリフト揚降システムを開発する上で、入念な技術調査が行われてきた。流体力学においてはその計測手法が長らく研究されており、理論的工学的研究が数多く存在する。その中で、下にあるようないくつかの技術が検討された背景がある。

- ・写真計測
- ・締め切り法
- ・PIV, PTV
- ・電気プローブ、光ファイバープローブ、ワイヤメッシュなど
- ・X線・ γ 線
- ・静電容量方式

これらのうち、実験により写真計測、PIVなどの手法がまず検討されてきた。しかし、撮影された画像から有益な情報を得ることは困難であった。

次に、電気プローブ、光ファイバープローブ、ワイヤメッシュなどの方法が検討されてきた。しかし、これらは粗大固体粒子を含む系には適用不可という側面がある。

X線・ γ 線を利用する方法に関しては、固気液三相（三成分）だと体積率を取得する技術が存在しないことに加え、放射線を取り扱うので大口径化などの点で見通しが不透明であるという問題点があり、静電容量方式でも固気液三相だと体積率を得られず、軸対称性が崩れた場合などは計測できないことが予想されるのである。これらの理由により、超音波によって流体を計測する試みが行われてきた。様々な取り組みが各所で進行中であるが、例えば共同研究を行っている北海道大学においては純粋な物理学的アプローチに基づく技術開発が行われてきた。しかし、混相流には膨大な変数が存在しモデル化が極めて困難である。従来支配的であった光学的な計測も使用できず、また、光学的計測と異なり超音波計測においてはノイズの影響が極めて大きいことが実験的に知られており、信号波形から人為的に特徴を抽出するアプローチが限界に達しつつある。

混相流計測には、X線や γ 線を利用したものや、静電プローブを利用したものなど様々なものが存在する。古いものだと

1.2.3 その他の研究

シミュレーションを活用するアイデア自体は、本研究室においてかねてより提案されてきた。いかに数値計算の検討を行う材料となる研究を紹介する。

例えば2023年には、管の断面を模した系での数値計算および、得られた信号波形をもとに気泡のサイズと位置を機械学習によって推定する研究がWangによって行われた。この中で、気泡がたった5つかつシミュレーションという条件下でも予測が困難であると示唆された。しかし、この研究にはデータセットの統計に関する議論が行われておらず、よりバランスされたデータを用いることによって再現できる可能性がある。また、その中で実機実験の

必要性と3次元シミュレーション、固気液三相流のシミュレーションを行うことを提案している。

2024年には尾花によって上昇気液二層流の超音波計測の技術がまとめられ、超音波のTime-stripイメージをもとに学習させるアプローチにおいてスラグ流・チャーン流の識別が行われた。また、この中で数値計算による計測データを学習させることができることが提案されている。

2025年には渡辺によってCNNを用いた相体積率及び見かけ流速の推定が行われ、有効な前処理手法についての調査が行われた。その中で二相流においては高精度での推定が可能だが、固気液三相流では困難であると主張した。しかし、全体的にデータが極めて少なく、それゆえ十分なテストデータを用意できず、有効かどうかの検証が十分ではない。また、学習されたパターンの物理現象を、計算機理論と照らし合わせて議論する必要がある。

他にも、純粋な流体力学的な固気液三相のシミュレーションとしては、例えば[10]や、

1.3 研究目的

以上に述べたとおり、従来の流体計測技術では当面の技術的課題を解決できず、我が国においては主に北海道大学と我々のチームで超音波での技術的開発が目指されてきた背景があり、本研究室においても関連研究が行われている。前述のとおり系が極めて複雑であり、物理的な現象論的アプローチも限界に達しつつある。そこで、本研究においては複雑系の取り扱いに強みを持ち、それらの特徴、表現をデータから取得できる可能性のある深層学習の技術を用いて新技術を開発することを目的とした。とくに、相体積率を推定する目的のもと実験データおよび数値計算を活用してデータ入手し、現象論に基づいた考察を行うことを目的とする。

1.3.1 本論文の構成

まず初めに研究の発端となった状況及びその動機に触れることによって動機を示し、そのうえで各所で様々な研究が行われてきたことを述べた。その中で顕著なものに焦点を当て、流体工学分野での混相流分野の概要や、流体計測技術を調査した。それを受け、本稿において数値計算を活用して得られた知見やデータを信号処理によって適切に機械学習・深層学習と組み合わせ、新たな計測技術を提案する。その際、使用した技術を技術的背景としてまとめ、本稿の核をなす数値計算、そのデータの処理を体系づける信号処理、そして得られたデータをもとに予測を行う深層学習について概論を示し、それらに基づいて本稿における数値計算の結果とそれに基づく知見、さらにそのデータを学習させた場合の性能と評価、今後の展望を示す。

第2章

技術的背景

2.1 超音波計測

超音波とは振動である。それゆえ、媒体を必要とする。その媒体の物性によって減衰や反射の特性が変化するが、伝播した超音波、すなわち計測物体の振動の情報を圧電効果を利用することによって電気信号の形として取得し、適切に変換することによってはじめて信号波形を計測することが可能となる。それらは電子回路によって適切に処理され、信号波形として対象物を計測した際の情報を利用できる。本研究においては電気回路については簡単に触れるのにとどめることとし、あくまで取得された計測波形に基づいて議論を行う。

超音波を含む音は、周波数、強度、波形で表すことが可能である。すなわち A を振幅、 ω を各振動数、 ϕ_0 を位相とした際に、音は

$$f(t) = A \sin(\omega t + \phi_0) \quad (2.1)$$

として表現されるので、周波数 $f = \omega/2\pi$ 、強度 $I = \frac{1}{2}Z_0A^2\omega^2$ 、波形 s として表現できる。

超音波の性質として、周波数が高いほどまっすぐ進みやすい一方で、強度が減衰しやすいというものがある。超音波は物質の界面で反射する性質がある。これらの反射と入射・および減衰と透過の影響を特徴づける量が音響インピーダンス $Z = \rho c$ （密度×音速）である。

Z_0 が大きく異なる物質の界面では超音波は反射する。ゆえに超音波は液相から固相に入ることはできるが、気相に衝突した際にはほぼ全反射される。

2.2 音響信号処理

これら超音波計測の際の信号を処理する方法論について述べる。これらについては音声信号処理に参考とすべき内容が多く、本研究に対しても有効と思われる手法に絞り紹介する。

2.2.1 数理変換

信号は目的に応じて適切に変換される必要があり、それを行う手続きは長い歴史の中で十分議論されている。フーリエ変換やヒルベルト変換は頻繁に用いられる。フーリエ変換においては定常性の仮定を置く目的で STFT[?] といった派生形があるが、今回は使用していない。ヒルベルト変換に関しては、[?] を使用した。

2.2.2 超音波画像法

超音波画像は、特に医療分野で広く用いられている。妊婦のお腹の中の胎児を可視化しようとした場合には、人体に影響を及ぼす電磁波などよりも、力学的な刺激であり人体に無害な超音波を用いて可視化することが好まれる。ここで用いられているのが、超音波画像法と呼ばれる方法である。これは、超音波パルスを照射してその透過波、反射波を記録し、その強度に応じて色分けして表示することによって画像を得る手法である。これらは、一般に信号波形の包絡線を取得し、適切に対数圧縮を施すことによって実現される。

その手続きを以下に示す。

Input: Signal waveform data $s(t)$, trigger detection function $\text{TriggerDetect}(\cdot)$, segment length L , number of vertical repetitions N

Output: Ultrasonic image data $I \in \mathcal{R}^{H \times W \times C}$

1. $T \leftarrow \text{TriggerDetect}(s(t))$ (Extract the list of trigger time points)
2. **for** $i = 1$ to N **do**
 - (a) $t_i \leftarrow T[i]$ (Time point of the i -th trigger)
 - (b) $v_i \leftarrow s(t_i : t_i + L)$ (Obtain the signal segment of length L from the trigger time point)
 - (c) $I[i, :] \leftarrow v_i$ (Store as the i -th row of the ultrasonic image)
3. **end for**
4. Output I (the generated ultrasonic image data)

2.2.3 ノイズ除去

本研究における学習データに関してだが、想定される電圧を超えていたため、欠損値が多く存在していることが確認されている。これらに関しては、暫定的にすべて 0 で埋め合わせるという操作を行った。

また、命名規則が誤っているものが存在した。対応表の中に記載されているのにもかかわらずデータが存在しなかったり、あるいはその逆の場合が見られた。また、データそのもの

が破損しておりロードできないものも存在した。これらに関しては、筆者が一つ一つ確認して除外あるいは修正し、ファイル名と誤りなく対応するように変更した。具体的には、元データ 408 のうち、目標値が存在するが信号がないものが 35、信号が存在するが目標値が存在しないものが 47 存在した。これらは、時刻で命名されているため数分のずれがある場合がおおく、これらを手作業で修正した。

また、データが産総研由来のものに関してだが、トランステューサを管に近づけすぎたために多重反射と干渉しあってしまい、特別な処理が必要である。今回は対応には至らなかった。

2.3 数値計算手法

本研究においては、実機計測データに加え、シミュレーションによって生成した計測データも利用した。ただし、固液二層において機械学習モデルを用いて実機データを評価する際には、実機データが混入しないよう細心の注意を払った。また、実機を模した機械学習用データを作成することを目的とした。

2.3.1 計算原理

超音波の伝播については波動方程式によってモデル化されており、系の時間発展を記述することが可能である。この方程式は原理的には二階の非線形偏微分方程式であるが、流体の保存則を活用することによって複数の一階偏微分方程式に分解することができ、数値的にも安定した計算が可能になる。

例えば、減衰なしの流体のもっとも単純な系の運動を記述する方程式として運動量保存則、質量保存則、圧力一密度の関係式が存在する。これらはそれぞれ

$$\frac{\partial \mathbf{u}}{\partial t} = -\frac{1}{\rho_0} \nabla p \quad (2.2)$$

$$\frac{\partial \rho}{\partial t} = -\rho_0 \nabla \cdot \mathbf{u} \quad (2.3)$$

$$p = c_0^2 \rho \quad (2.4)$$

が挙げられるが、これらを整理すると

$$\nabla^2 p - \frac{1}{c_0^2} \frac{\partial^2 p}{\partial t^2} = 0 \quad (2.5)$$

の、波動方程式を得る。

すなわち、これらの波動方程式の解は、流体の保存則の解と等価である。実際は減衰などのより現実に即した効果を付した項が追加され、より複雑な方程式となる。これらの式を離

離散化することによって、連続な量を対象とする本来の偏微分方程式を計算機で数値的に解くことが可能となる。

2.3.2 疑似スペクトル法 (pseudospectral method)

シミュレーションにおいてはいくつかの数値的なモデルが存在する。そして、それらへの最適なアプローチは系に依存する。それらに対して、heterogeneous(不均質)な系、つまり様々な材質から成る系についての解を求めたいとする。こういった問題を解くには、有限差分法 (finite difference) あるいは有限要素法 (finite element) が考えられるが、有用な精度を達成するには音波長あたり 10 点が必要である。これらの方法では、過度に計算コストがかかってしまいがちである。

これらは、有限差分法が、もとの関数の近傍で近似を行うことに起因する。勾配を評価する際、高精度の値を得るにはより高次の多項式をできるだけ多くの点でフィッティングする必要がある。これらに対処するのがフーリエ選点法である。この手法は、データ点すべてにフーリエ級数を割り当てる。基底関数が正弦波的な形状を持つために、有限差分法と異なり高次の多項式を必要とせず、かつ 2 点でフィッティングできるので必要なグリッド数も少ないものである。よって、波動伝播においてはより効率的な計算手法であるとされる。

2.3.3 安定性解析

系の方程式を記述して、それを数値的に解く場合にはいくつかの検定が存在する。

1. 離散化に伴う連続量との乖離
2. 安定性解析
3. 計算結果の正しさ

離散化に伴う量は、 Δt を十分小さくとることによって導関数に一致することはここでは自明とする。よって、重要なのは数値的な誤差が時間発展によって増大してしまうか否かである。これらは、十分 Δt を小さくとることが望ましい一方で、計算時間の制約からできる限り粗くとることが望ましい。しかし、ここでもいくつかの検定が存在する。ただし、一般に適切な領域で Δt を小さくとって計算をやり直し、その値が収束することによって正しさを証明する手法である。低周波の波長の伝播の計算はより高周波の伝播によって保障されているので、高周波の計算がそれを担保するのである。

2.4 機械学習

機械学習は、データからパターンを抽出する技術である。より詳しく言えば、入力と出力の関係をモデル化し、モデルによる予測結果と目標値との誤差が小さくなるようにモデルの

パラメータを更新する技術である。このような更新を行うためには誤差関数の値を最も小さくする方向に適切にパラメータの更新量を求める必要があり、そのために誤差関数そのもののパラメータに関する勾配を評価する必要がある。パラメータの更新量を求める最適化アルゴリズムには、確率的勾配降下法 (Stochastic Gradient Decent, SGD) に基づいた数々の手法が存在する。

この技術を駆使し、本研究では、超音波信号波形から相体積率を推定する回帰問題として定式化する。入力 $\mathbf{x} \in \mathbb{R}^{1 \times W \times C}$ (W : 信号長、 C : チャネル数) から連続値 $y \in \mathbb{R}$ (相体積率) を予測する関数 $f : \mathbb{R}^{1 \times W \times C} \rightarrow \mathbb{R}$ を学習する。

本研究では深層学習 (CNN、Transformer) を中心としたニューラルネットワークアプローチを採用する。これらの手法は、信号波形から物理量を推定する関数を直接学習できる利点がある。

2.4.1 正規化・正則化

今回設計したモデルには、学習を円滑に行うためにいくつかの統計処理を施してある。今回、シミュレーションで得られるデータは数 khPa にも及ぶ圧力変動であるのに対し実機試験で得られるデータはトランスデューサの一 -2° + 2V の範囲の電圧変化である。シミュレーションのデータを学習に利用し、実機データでの性能をテストするというアプローチをとるとは言え、そのままでは入力データにおける数値的な変動があまりに大きい。ゆえに、データのスケールをそろえるという操作が重要となる。このような操作は正規化と呼ばれ、単にシミュレーションと実機に見られる値の差異のみならず、同じ入力間のデータや、隠れ相を通った後のデータに対しても同様に重要である。

2.4.2 モデルの種類と概要

深層学習の技術はデータが大量に存在し、モデルが不明であり、かつ「存在するとわかっている」ような分野において発展してきたという背景がある。Transformer とは自然言語処理の分野で考案されたアルゴリズムであり、自然言語のみならず画像処理、系列処理といった様々な分野に応用され、従来のアプローチの性能を大きく上回るという研究成果が様々な分野において発表されている。本研究では、特徴、表現をデータから取得できる可能性のある深層学習の技術を用い技術的課題の解決を目的とした。とくに、相体積率を推定する目的のもと実験データおよび数値計算を活用してデータ入手し、現象論に基づいた考察を行うこととする。

また、CNN の性質として、画像中のパターンの、位置、回転、大きさに対して頑健性を持つという性質がある。あるいは設計思想として、画像中のパターンの普遍性が定性的にわかつており、これらを効率的に学習できるような構造として CNN が考案された背景がある。

例えば、我々は画像中のネコのパターンを、ネコが拡大されようが回転されようが、位置をずらされようが検出することができる。これらを用いることは、管径によらず、またトランデューサの微妙な位置のずれによらず物理量を予測可能なパターンの学習につながるので期待される。

なお、これらは CNN の畳み込み構造、積み重ねによる局所的受容野を広くとることによって達成される。局所的受容野が狭すぎれば、そもそもそのパターンを認識できず、ゆえに位置的な頑健性を得られない。よって、多くの文献で採用されているような、 3×3 のカーネルで設計された数々のモデルをそのまま使うことはできない。

2.4.3 モデル解釈

CNN やほかのアーキテクチャで学習された特徴の解釈に用いられる方法はいくつかある。例えば、学習したカーネルそのものをプロットする方法である。これらに関しては、深層学習の際に用いたカーネルをすべてプロットするというものである。一般に、[11] にあるように、下層のカーネルほどエッジのような機械的な特徴を、上層に行くほど高次の概念を学習していると解釈される。

一方、入力のどの領域が予測に最も寄与しているかを可視化する方法として顕著性 map(saliency map) というものがあげられる。これらは、入力のどの領域に大きな重みを割り当てているかを確認する方法である。その最たるもののが Grad-cam[12] と呼ばれる方法である。これらの機能の詳細に立ち入る前に、その応用例に焦点を当てる。以下は、原論文にあったような、自然画像を入力として分類を行うモデルである。ある画像に犬が含まれるか、猫が含まれるかを識別する場合は、まずそのカテゴリに属する確率を計算し、そのうえで最大の確率を持つクラスに割り当てるという処理がされる。(Decision theory, 決定理論と呼ばれる) 注意すべきは、この画像には、犬に属する確率も猫に属する確率も等しく存在する点である。その上で、Gradcam は、畳み込み層最終の出力の変化が、Softmax 関数に通す前の値にどれだけの変化を起こすのかというものを可視化する。式で言えば、

$$\alpha_k = \frac{1}{M_k} \sum_i \sum_j \frac{\partial a^c}{\partial a_{ij}^k} \quad (2.6)$$

の値を計算し、これらの重みでもって最終層を強調する。これらの解釈としては、例えばある位置のピクセルの画素強度がわずかに変化したことにより、計算した確率に大きな変化をもたらしたのならば、それは画像中で重要な箇所であると解釈される。それらの値を各ピクセルに対して計算し、その変化の度合いの大きさに応じてヒートマップを作成することにより、その画像に対する重要な箇所を可視化することができる。強調すべきは、ニューラルネットにおいては全く同型の写像の機能を持つ関数が学習された場合でも、別々の重みが得

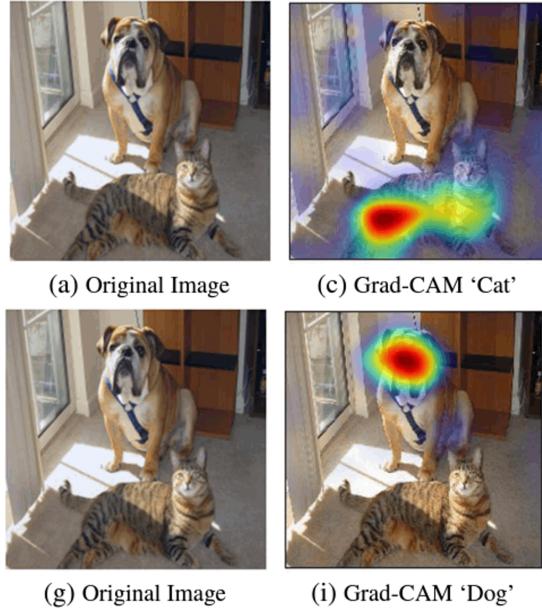


図 2.1: 画像入力に対する saliency map を可視化したもの。1枚の画像に犬と猫が映っているが、犬、猫それぞれのクラス予測に対応する入力箇所が可視化されている。

られるということである。Bishop[13]によれば、これらは同様に良いモデルであるとされる。しかし、今回のような事例では、ある重みのセットよりも好まれる重みのセットが存在する。実機試験においては超音波パルスの形状が機器の性質により扁平になってしまうケースがあり、予測に寄与しない部分にまで同様の重みを割り当てるモデルはロバストな予測に寄与しない。なお、Grad-cam の Cam は Class Activation Mapping のことであり、今回のような回帰を行う場合には名称として適切でない。しかし、分類と回帰の違いは最終出力を Softmax に通すか否かであり、最終出力における貢献を可視化する手法であるので回帰の場合にも同様に適用できる。本研究では、[11]に倣い、“saliency map”という名称を用いる。

2.4.4 ベイズ最適化

機械学習は、人間が主観的に決定するパラメータを必要とする場合がある。これらをパラメトリックモデルと呼ぶ。これらは、予測精度が向上するようにいくつものパラメータを人間が試すことが多いが、それらへの正当性が不明であり、わずかな変化に対して脆弱である場合がある。これらのハイパーパラメータ最適化に際し、ベイズ最適化というアプローチがしばしば採用される。ベイズ最適化は、パラメータの事前分布を仮定し、その分布に従ってパラメータをサンプリングすることによって、最適なパラメータを探索するアプローチである。

20 第2章 技術的背景

ローチである。特に、ガウス過程をサロゲートモデルとして、ハイパーパラメータの不確さを統計的に評価し、その値に応じたパラメータの提案を獲得関数によって規定し探索を行う。

第3章

実験手法・実験系

3.1 実験装置・計測機器

協力を受けた海洋技術安全研究所の実験設備の模式図を以下に示す。

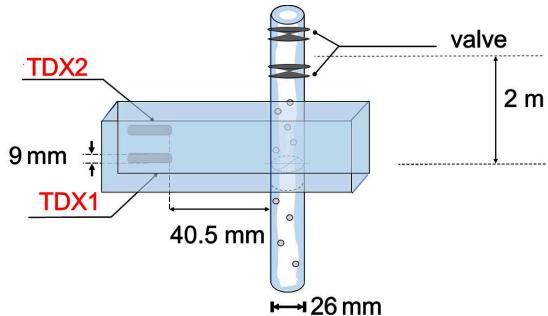


図 3.1: 実験装置の概念図。パイプの中を空気・ガラスビーズが流れている。

これら実験系は、上昇鉛直管における固液二層流、気液二層流、固気液三相流を超音波で計測した場合の信号データのほか、空間平均の相体積率や画像データに関しても取得することが目的とされており、いくつかの設備が複合されてある。信号データを取得できるトランスペューサ及び画像データを取得でき超音波照射と同期する設定のもとハイスピードカメラが設置されている。なお、空間平均の相体積率は締め切り法と呼ばれる手法で計測されており、これは上下バルブを同時に遮蔽し、バルブ間に取り残される媒体を測定する手法である。固相に関してはガラスビーズの個数が数えられ、気相、液相に関しては液相のみ体積率の比として測定される。1から液相、固相の割合を引くことによって気相の体積率が求められる。

概念図を以下に示す。この図のポンプにより流体の駆動力を得、適切に空気を注入することによって混相流が再現される。

Transducer settings(TX-4-5-8-40, Met-Flow)	value	Unit
Ultrasound frequency	4	MHz
Pulse repetition frequency	3	kHz
Cycles of ultrasound pulse	4	
Sound speed	1480	m/s
Sampling rate	52.08	MHz
Active diameter of transducer	5	mm
Measurement time	5	s

表 3.1: transducer settings in the experiment

3.2 実験条件・手順

これら実験系は、上昇鉛直管における固液二層流、気液二層流、固気液三相流を超音波で計測した場合の信号データのほか、空間平均の相体積率や画像データに関しても取得できることが目的とされており、いくつかの設備が複合されてある。信号データを取得する目的でトランスデューサが、画像データを取得する目的で超音波照射と同期する設定のもとハイスピードカメラが設置されている。なお、空間平均の相体積率は締め切り法と呼ばれる手法で計測されており、これは上下バルブを同時に遮蔽し、バルブ間に取り残される媒体を測定する手法である。超音波計測、流量計測が終了次第、二つのバルブを急閉し流れを遮断する。内部の水位及び固体粒子の個数を数えることにより、液相、固相の体積分率を得ることができる。ただ、この手法においては急な流れを堰き止めることによるバルブの劣化が著しく、水漏れが発生する場合がある。よって、気相は実際の値よりも大きめに、液相は実際の値よりもやや小さめに測定される場合があることに注意が必要である。一方で、そのような値は極めて微小である。トランスデューサの設定や系の物性についての条件を以下に示す。これらは [9] による報告をベースに提供された資料があり、それらによると条件は以下のようであった。これらの仕組みに関してだが、使用したトランスデューサの原理は、ある固定された位置における音圧変化を電圧に変換し、それを信号波形の形で記録するものである。そして、それらの音圧一電圧の関係においては線形な範囲が存在するとされ []、本実験においては機器の指定する印加電圧内で実験していることから線形であると考える。

この領域では、シミュレーションで得られる音圧変化と、実機において計測される電圧変

化は、適切なスケール化及びダウンサンプリングを施すことによって入力において数値的に同じ統計・次元を持つようにすることが可能である。

3.3 データ取得方法

本研究における学習データに関してだが、計測機器の不具合といった何らかのエラーにより不適切な値を取ることがある。そういう値は適切な学習を阻害しうるので適切に除去する必要がある。これらに関してはデータ分布を適切な手法で確率分布としてモデル化し、値を取る確率が極めて小さいものを外れ値として除外するという案が考えられる。

今回、実機データとその際の測定記録を拝見した際には、恐縮ながら命名が誤っていたり、データが破損している事例がしばしば見られた。例えば、実機測定データは存在するがそれに対応する相体積率の目標値がなかったり、その逆がみられた。これらは筆者が手作業で確認し、修正した。今後このデータに基づいて解析を行う場合には、解析の担当者の負担が増すがあるので、注意されたい。

また、後述するように、実機データにおいてはシミュレーションと異なり尖ったピークは一般に現れない。実際には尖った先端を切り取って台形にしたような信号波形になることが確認されている。これらに対し、適宜関数をフィッティングしてピークを補完し、より正しい値でのスケーリングを行うことが考えられる。その技術は、例えば[14]の技術を使えば解決できる可能性はある。

第4章

計算系

本研究においては、実機計測データに加え、シミュレーションによって生成した計測データも利用した。すなわち、シミュレーション生成のデータをもとに機械学習モデルを訓練・検証した後に実機データにおいてそれを評価するモデルも存在する。実機を模した機械学習用データを作成することを目的とした。

4.1 計算系の設計

数値計算を実行するためのオブジェクトを点群として定義し、それらに対し適切な物性値や信号遅延などを与えることによって実機に近い測定データを得ることが可能となる。計算系において存在する媒質は、固気液三相流の場合も含め石、塩化ビニル、水、空気、ガラスであり、これらをトランスデューサによって計測するという設定をなす。一般的な設定において、2次元では任意のセンサー配置ができる一方、現実の測定に即したビーム収束などは再現できない。一方、3次元では送信器、受信器でそれぞれ一つのトランスデューサしか実装できないが、各素子への信号の送信に時間遅れを持たせて、超音波に指向性を持たせることが可能となる。計算に使用した各種物理量は config.json にも記載されているので、そちらを参照されたい。以下は、それぞれの設定理由を示す。

4.1.1 グリッドサイズ

次に、計算を行う上では格子点、その幅を計算機の性能を鑑みながら決定しなければならない。理想的には、計算機の性能が、シミュレーションに必要な性能を大幅に上回っている状態が望ましく、計算機の制約を考えずに設計したい。しかし、研究室の計算環境ではやはりそれも考慮して計算系の設計をする必要があった。以下、計算系の要件を示す。

まず実験設備のスケールとしては、トランスデューサが超音波を照射しその反射波を記録

する目的から、

$$l_x \text{ [mm]} > 82 \text{ [mm]} \quad (4.1)$$

である必要がある。また、幅に関しては管の直径よりも太くある必要があるので、

$$l_y \text{ [mm]} > 32 \text{ [mm]} \quad (4.2)$$

が必要である。なおこれらは下限であり、実際はもう少しゆとりを持たせることが好まれる。

他方、計算を正確に行うための計算理論による要件を示す。先に述べたように、波動の位相を正確に取得するためには、 $\lambda_{min} = c_{min}/f, c_{min}$ を、系の構成要素の中での最も遅い伝播速度として

$$2\Delta x \text{ [m]} < \lambda_{min} \text{ [m]} \quad (4.3)$$

である必要がある。例えば固液二層の場合では律速が水なので $c_{min} = 1500 \text{ [m/s]}$, 気液・固気液では空気が律速となるので $c_{min} = 340 \text{ m/s}$ となる。ゆえに、例えば固液を例にとると、現在使用している超音波の波長が 4 MHz であるので

$$\Delta x \text{ [m]} < \frac{1500}{2 \cdot 4 \cdot 10^6} \text{ [m]} = 0.1875 \text{ [mm]} \quad (4.4)$$

を満たさなくてはならない。ただし、2倍、3倍などの高周波成分などの量を再現しようとした場合には、その分だけ小さくとる必要がある。これらは、フーリエ変換のスペクトルで 12 [MHz] のピークがわずかに見られたためそれらを再現する目的で 0.0625 [mm] よりも小さい値に設定する必要があった。

ここで、格子点数の要件について記す。今 $l_x = N_x \cdot dx > 82 \text{ mm}$ であるので、

$$N_x > 1312 \quad (4.5)$$

が示される。計算機上は 2 の累乗だと計算効率が良いので、 $N_x = 2048$ を採用してある。同様の議論で $N_y > 512$ が必要だが、これでは計算系の境界に接してしまうので望ましくない。そこで、それよりも大きくかつ効率が良い値として $N_y = 768$ を採用した。

最後に、 N_z, dz について触れる。これらは、計算機の上限から $N_z = 128$ とした。これらにより GPU 上で約 20GB の仮想メモリが割り当てられ計算が実行された。

4.1.2 固液二層流

系を規定する媒体は、ガラスおよび水の二種類である。また、実験記録にはガラスピーズの直径が 2.5 mm と記載されてある。よって、事前にガラスピーズの個数を規定しておき、それを空間的に配置して計算系を作成した。この際、複数のガラスピーズの座標は Box-Muller 法と呼ばれる乱数生成のアルゴリズムをベースに、適当な検定を設けることによって生成した。以下にその詳細を示す。これらによって生成した座標は

$\{x|x \in [-1, 1]\}, \{y|y \in [-1, 1]\}, \{z|z \in [0, 1]\}$ の区間で生成されており、これをグリッドサイズの分だけ拡大することによって計算系の座標として利用してある。トランステューサの設定としては以下のものを用いた。

4.1.3 気液二層流 (未実施)

今回は空気と水の二種類によって系が決定される。固液二層との違いは、気泡の形が球形を成すとは限らず、またその形状も複雑であり、体積も一定でないということである。著しく非軸対称であり、分裂の最中のもの、合体の最中のものなど混迷を極める。一方で、気液二相に関しては画像解析に基づくいくつかの知見が存在しているのも事実である。例えば坂口ら [15] の研究によれば、大きい気泡は管中央に、小さい気泡が管壁付近に分布することが明らかになった。また、古典的な教科書である [16] によれば、 $6 \times 10^{-4} \text{ c.c}$ 程度の小さい気泡に関してはほぼ球であると仮定してよく、この値を超えると扁平となり振動しながら上昇する。次に、体積が 5cc よりも大きくなると球の一部を切り取ったような形になり、また、その仰角は泡の体積によらず $46^\circ \sim 64^\circ$ となる。最後に、管いっぱいを占めるような大きな泡に関しては、形状定数 α 、気泡の上昇速度 U 、重力加速度 g 、よどみ点における気泡表面の曲率半径 R を用いて

$$\alpha^2 U^2 = gR \quad (4.6)$$

の形状をなす。また、 U は円管の内径を D として $0.48\sqrt{gD/2}$ に等しく、 $R/D > 0.26$ ならば半径 R の帽子型形状の泡よりも小さい。ゆえに、管を埋めるほど大きな泡は大きい泡へと追いついて合体することを示すという。最後に、これら帽子型から十分下方では、質量保存の式から

$$\pi \frac{D^2}{4} U = \pi \frac{D^2}{4} - \left(\frac{D}{2} - d\right)^2 \sqrt{2gx} \quad (4.7)$$

が得られ、基本の先端からの距離を x として

$$\frac{2d}{D} = 1 - \sqrt{1 - \frac{U}{\sqrt{2gx}}} \quad (4.8)$$

の関係式を成すという。さらに、村井の研究 [17] らにより気泡径とその分布が統計されており、その形状は、ポアソン分布に酷似している。これらから、技術的に大まかにモデル化可能な領域と、その正しさが確認される。すなわち、超音波伝播をシミュレートする上で気泡の数 N 、形状の関数 S_i 、気泡それぞれの座標 \mathbf{r}_i を決定する必要がある。ここで、形状のモデル化に関しては極めて難しいので、構成要素としては球あるいは円柱を組み合わせただけとする著しい簡略化を行った。ゆえに、これら形状は球の直径 D_i と円柱の高さ h_i の関数としてよく、また、座標 \mathbf{r}_i の確率分布は D_i によって規定されると仮定できる。これらから、

暫定的に条件を満たす分布を以下のように定義して以下議論を進めることとする。 N は既知とする。

$$D \sim Pr(\nu) \quad (4.9)$$

$$h \sim Uni[0, a] \quad (4.10)$$

$$S = \begin{cases} Sphere(0 < D < 1mm) \\ Oblate(1 < D < 10mm) \\ Spherical-cap(10mm < D) \\ fill-bubble \end{cases} \quad (4.11)$$

ここで、spherical-cap に関しては仰角が 46.64° と定まっているため、 60° と定義することによって、曲率半径 R の関数として体積を導出できる。これは簡単に計算可能で、 $\theta = \pi/3$ の時は

$$V(R) = \frac{16 - 9\sqrt{3}}{24} \pi R^3 \sim 0.0539R^3 \quad (4.12)$$

と計算できる。これらを実装することにより、上昇気液二層流における気泡流、スラグ流、チャーン流、環状流のうち気泡流と環状流のシミュレーションを行えることが期待される。スラグ流・チャーン流は著しく不規則なので、大変な技術的困難が予想される。

4.2 数値計算結果

実際の数値計算による結果と、その概要を示す。目安として、研究室の計算環境である Nvidia RTX 4090 を利用した場合には、1 データあたりおよそ 4 時間を要した。前節での物性値をもとに数値計算を行った。

4.2.1 液相のみ

まず、液相のみのシミュレーションが妥当かどうかを実機をもとに検証する。出力された結果は以下のようなものであった。液相のみの条件に関しては実際に実験されており、以下のような結果が存在する。一つのデータを示す。これらの信号波形について、より詳細な解析を行った。また、シミュレーション生成の信号のうち、管壁からのものを詳細に解析する。信号に対してはヒルベルト変換により検波処理を行っており、包絡線を取得してある。このとき、以下の結果が得られる。これらを比較すると、定性的にはシミュレーション側では山のような形になっており、4 回繰り返した信号波形のピークが見えにくい一方で、実機実験の方では先がつぶれたような形状をしていることがわかる。これらのピークの間の時間差を取得することによって、材質がわかればその厚さが、厚さがわかれば媒体中の音速並びに

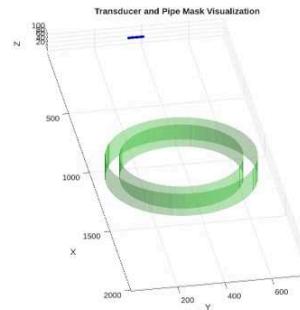


図 4.1: 数値計算の計算系の模式図。緑色のものがパイプを模しており、周りを水で満たしているものとする。

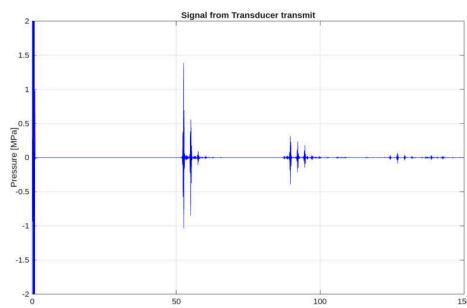


図 4.2: 液相のみの場合のシミュレーション信号波形

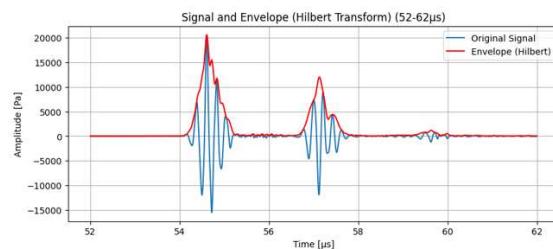


図 4.3: シミュレーション生成信号の、管壁付近の信号波形及びヒルベルト変換による包絡線の可視化

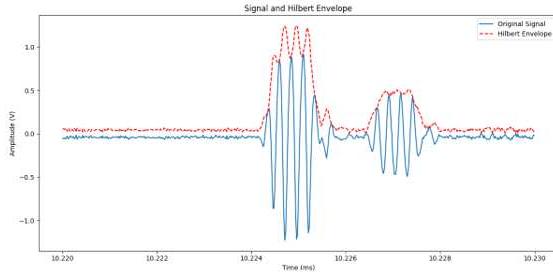


図 4.4: 実機の管壁付近の信号波形及び包絡線を可視化したもの。

材質が決定できる。この超音波厚さ測定に関しては付録 7 に詳細な解析結果を示した。この結果に基づきそこでは、音速の値としては 2790 m/s を採用した。次に、この領域に対してフーリエ解析を実行した。まず、実機データのパイプ部分に対する周波数成分を解析する。これらから、定性的には 4, 8 MHz の地点にピークがみられる。使用しているものとちょう

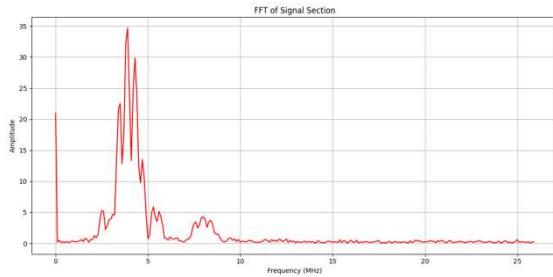
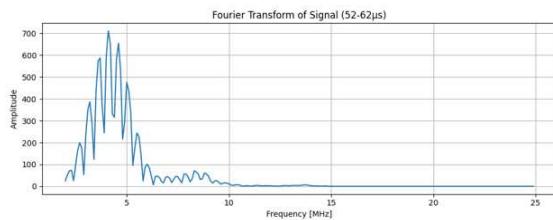


図 4.5: 実機信号の、管壁付近の信号波形に対するフーリエ解析結果。4, 8 MHz の地点にピークがみられる。

ど倍の周波数成分がみられるが、これらは倍音 (second harmonic) と呼ばれる。

次に、数値計算によって生成した信号に対するフーリエ変換を行った結果を示す。以下は $CFL = 0.03$ で行ったものである。次に、 $CFL = 0.01$ で行った結果を示す。これらから、

図 4.6: $CFL=0.03$ に対する信号波形のフーリエ解析結果。実機と同じ 4, 8 にピークがみられる。

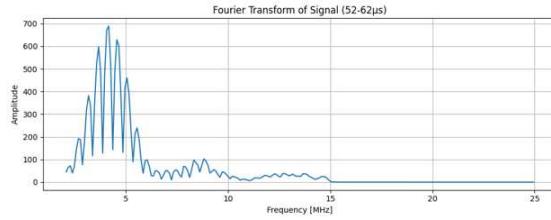


図 4.7: $CFL=0.01$ に対する信号波形のフーリエ解析結果。実機にはない 12 の成分を持っている。

周波数空間の観点から、 CFL の値としては 0.03 が好ましいとした。一方で、これらは計算の成立条件を満たしている (7) ので、以下すべてのシミュレーションはこの値のもと行った。

4.2.2 固液二層

3 次元シミュレーションによって計測信号波形を生成した。これらは、機械学習用に使用するものである。基本的に機械学習用データは多いほうが望ましいが、多数は不可能であった。故に 213 のデータを生成し、それによって訓練を行った。その結果を以下に示す。

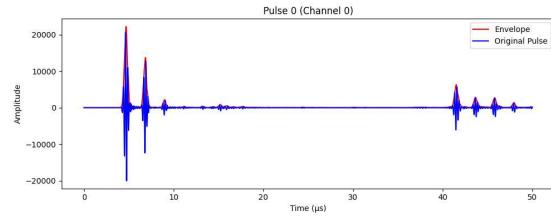


図 4.8: 固相粒子を含めた場合の信号波形

第 5 章

提案手法

今、適当な何らかの測定を実行している間、その測定領域における真の値が存在する。これらによって超音波の信号波形が何らかの影響をうけて、測定結果として入手することができる。

ここで、信号波形から体積率を求めるのと逆の場合、すなわち体積率から信号波形を求める順問題は、比較的容易に解くことができる。固相粒子の個数および一つの粒子の体積、およびその相配置が既知とした場合には、波動方程式に基づく数値的な反復法によって超音波パルスの伝播を再現することができる。よって、数値計算シミュレーションソフトウェアを使用し、ある相体積率及びその相配置に基づく信号波形を生成した。

信号波形からそれに対応する相体積率を機械学習で推定する手法の一つには、連続値を推定する回帰モデル、すなわち

$$p(t|\mathbf{x}, \mathcal{D}) \quad (5.1)$$

を推定し、その期待値

$$\mathbb{E}[t|x] = \int tp(t|\mathbf{x}, \mathcal{D})dt \quad (5.2)$$

を評価することにより達成できる。よって、その回帰モデルの設計が問題となる。これらについてだが、設計の要件としては以下のものが挙げられる。

- ・入力信号の現れるピークの位置に関してロバストであること
- ・入力信号は $\mathbb{R}^{1 \times W}$ の形式を持つ。

ここで、信号は極めて長い系列を持ち、全結合型での機械学習モデルの学習にはパラメータ数が発散し計算を行うことが困難である。センサーの数並びに配置によっては管内の流動状態を推定するのに十分でない情報しか入手できない場合があるし、ここで用いている仮定が悪い結果を引き起こす可能性がある。以下に、センサーの数および配置に基づく提案手法を示す。

5.1 制約条件

前述 (chapter3.1,page21) のように、本稿で用いた海洋技術安全研究所の実験データは、対向する二つのトランステューサで円管を挟み、少し離れた位置においてもう一つのトランステューサを配置するような配置で実験を行った。ここで、超音波パルスを照射したトランステューサは片側であり対向側は透過波のみを、送信側は反射波および送信した際の信号をそれぞれ記録している。対向側の管壁内側からの反射波を計測できる場合、透過波の情報は不要であると考え、まずは一つでの学習結果を示す。実験系の設定に関する表 (3.1) では 3 kHz での prf, で 5 秒間の測定を行っている。すなわち、通算 15000 回の測定を行っている。これらの測定の度に対応する相体積率が存在するため、1 回の測定で相体積率を推定する機械学習モデルを訓練し、時間平均をとる必要がある。これらにおいて、大きく分けて計算機上の制約と実験上の制約が存在する。データセットのサンプルサイズが多すぎれば計算機のメモリにおさまらず、また、実験のスケールの問題で超音波トランステューサに配置可能な

5.2 手法

5.2.1 指標

例えば、[9] によると、気相体積率の推定においては、1 サンプルに対する Error rate として

$$\text{Error rate} = \frac{\text{True_value} - \text{Predicted_value}}{\text{True_value}} \quad (5.3)$$

を用いている。従来、本研究室においても同じ尺度が用いられた。しかし、本来の目的は構成方程式の精度を評価することであることを踏まえると、真値の値に左右されるような指標を用いることによって、本来無視できる誤差を過大評価する場合が存在するのは望ましくない。例えば真値が 0 に近い場合、精度を大まかに評価する目的であれば 2~3 の値を出力するようなモデルでもある程度有効であるが、この指標を用いる場合には誤差率が 30 % 等を示し有効でないとされる。そこで、今回の場合に適した RMSE による評価を行う。

5.2.2 固液二層に対する手法

前節のような制約・要請を解決する手法として、以下のようなアルゴリズムを提案する。すなわち信号波形を縦 1pixel の画像とみなし、CNN や Vision Transformer といったスペースな画像学習を行うこととする。ここで、このような問題設定は極めて異例なものであることに注意が必要である。画像処理分野において、一般的な機械学習の応用としてはあくまで分類的な用法が主流となっているからである。例えば、[11] を参照するに、現在広く用いら

れる画像分野における機械学習の応用には人物検出、顔検出、顔認証、物体認識・識別、音声認識などがあるとされるが、これらはすべて分類タスクである。なぜなら、これらはすべてデータが与えられたときに、そのデータ自身が所定のカテゴリに属する確率を計算するモデルにほかならないからである。

確かに、画像から回帰を行っている機械学習モデルは存在する。例えば、R-CNN[18]などは、画像に含まれる Object のカテゴリを決定すると同時に、その画像のどこにその物体が存在しているのかを決定する。これらの学習は、物体が属するカテゴリの確率を計算する分類モデル並びに、物体の存在するピクセルを目標値とした回帰モデル二者の訓練を同時に行うことによって達成される。ここでは詳細に立ち入らないが、注意すべきは、これらの学習は、それらを行う人間の脳の働きを模倣したものということである。人間の情報処理システムは複雑だが、人間ならば実現可能であるという事実があるからこそ、それを正しく予測する関係性が存在し、それを機械学習で抽出するアプローチが正当化される。一方、例えばいくつか人の顔から年齢を予想するような研究では、[19],[20] どれも MAE で 85%~90% 程度の精度を示すものの、モデルの正当性には議論の余地が残る。表面的に表れる年の取り方は必ずしも一定ではなく、健康的な人は若く見えるし、不健康な人は老いて見えるため、それらを数値として予測することが生理学的観点から適切であるかは不明である。ゆえに、年の取り方を定義する場合、健康的な人間だけを集めた人間のみを対象とするか、全体的に考慮するかはさらに議論の必要があると [20] は述べている。

なお、実装については [21] によると Pytorch が支配的なのでこれを用いた。詳細は別資料で示す。なお、今回の場合においては、センサーでの値の系列から管内流体の複雑系に含まれる潜在変数の値を推定する回帰モデルを設計する問題である。ここで、機械学習は瞬時の体積率を推定する

$$\mathbf{x}_n \in \mathbb{R}^{1 \times W \times C} \xrightarrow{f(\mathbf{x}, w)} y_n \in \mathbb{R}^1 \quad (5.4)$$

の関数として利用され、通時的な量は

$$\hat{y} = \frac{1}{N} \sum_n^N y_n \quad (5.5)$$

によって推定される。ここで、平均および分散を取得し、エラーバーも取得することができる。平均値においては比較的良好な一致が見られたが、分散が非常に大きくなってしまうという結果が得られた。この問題は、トランスデューサの数を増やし、チャネル数 C を増やすことによって解決できる可能性がある。その際、センサは対向ではなく垂直に配置した場合には、管内の状態についてより多くの情報を得ることができるために相配置の同定に役立つことが予想される。

5.2.3 固気液三相流に対する手法

気液二層流に対する数値計算は気泡形状、気泡体積、気泡配置、気泡数統計などのモデル化を含むため固液二相のモデル化と比して極めて複雑であり、固気液三相流においてはさらなる困難が予想される。また、瞬時の体積率も利用することはできない。一方で、トランスデューサを二つ用い、その相関情報を利用することは予測精度向上に寄与すると考えられる。このような場合においては、1パルスではなくすべてのパルスに対して一つの値を割り当てるモデルを学習するのが望ましい。すなわち

$$\mathbf{x} \in \mathbb{R}^{H \times W \times C} \xrightarrow{f(\mathbf{x}, w)} y \in \mathbb{R}^1 \quad (5.6)$$

の関数として予測する。ここで、 \mathbf{x} は超音波画像であり、 w はモデルのパラメータである。 y は相体積率である。モデルに関しては Resnet[22] を用いた。これらによって新しく提案されたアーキテクチャについてはいくつかの解析が存在し、例えば [23] によれば、より安定した学習を可能にする残渣接続 (residual connection) を用いることは、損失関数の表面が滑らかになる効果をもたらすことを視覚的に示している。これらにより、残渣接続なしの場合と比べて学習が局所最適解に陥る可能性が低くなることが期待される。

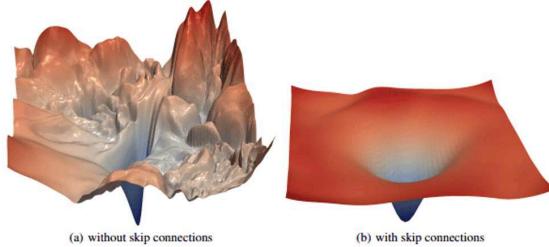


図 5.1: [23] より抜粋。残渣接続ありの場合と無しの場合の損失関数の表面を可視化したもの。残渣接続がない場合は表面が粗い一方で、残渣接続がある場合は表面が滑らかになっている。

第 6 章

学習結果

回帰モデルを MSE (Mean square error、平均二乗誤差) によって訓練し、その予測精度を評価する。評価に関しては、回帰で一般に用いられる RMSE(Root mean Square error), MAE(Mean Absolute error) を用いた。

6.1 固液二層流

以下は、その予測精度を評価したグラフである。ガラスビーズを固相として用いた場合、石を固相として用いた場合の固相体積率が色分けされてプロットしてある。

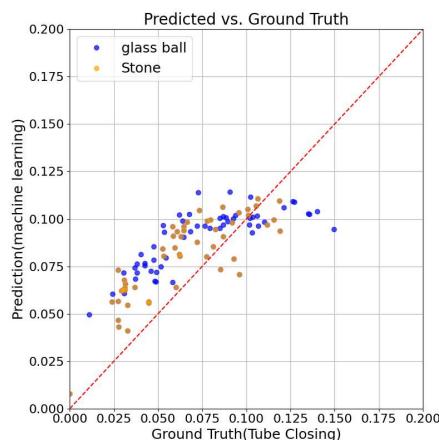


図 6.1: 縦軸が予測値を、横軸が実測値を示す。ゆえに、点群が $y=x$ に近ければ近いほど精度が高いと判断される。

6.1.1 課題

これらテストデータに対する偏りとして、相位積率の最大値が 0.15(正確には、2024 年データにおいて 0.149) というものがあげられる。ゆえに、0 から 0.15 までの値をランダムに予測したり、適当な一次関数からのサンプルでも RMSE の率はそれほど高くはない。このような議論を行う上では統計検定が必要である。平均すればある程度良い予測結果が得られる一方で、いくつかの欠点がある。まず一つに、機械学習の際、訓練データとテストデータ（実機）の評価が大きくずれる事象が数多く見られた。定性的に一定の類似性はみられるとはいえ、シミュレーションと実機ではデータにあまりに多くの差異がある可能性がある。

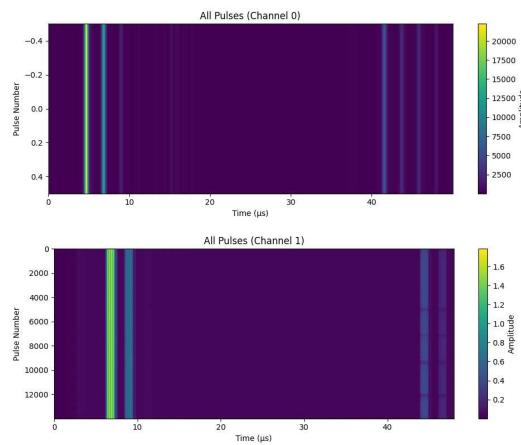


図 6.2: シミュレーションと実機試験のデータの比較。両者ともに超音波画像法 2.2.2 によって画像化してある。

この二つの画像は、そのサンプルである。超音波パルスの幅や、多重反射が明瞭に確認できる回数などに違いが見て取れる。それでも一定の精度を得られたのは、情報処理のメカニズムにおいて、学習の過程でたまたま十分にロバストで実機データを処理するのにも使用可能な局所最適解・パターンを発見したからである可能性が高い。事実、学習率をさげて訓練を行った場合には、訓練データに対してよい精度を示しつつ安定的な学習を行った一方で実機データの値を適切に予測することができなくなった。だが、それよりも重要なのは、予測に際し分散が非常に大きいということである。上記のグラフは平均値のみをプロットしたが、時間平均を計算する過程で評価できる分散の値も同時にプロットするとのように、著しく Error bar が大きく表示されてしまうという問題点がある。これらへの考察として、トランスペューサの数が少ないからというものが挙げられる。機械学習とは統計的なパターン認識技術にすぎないので、予測とは尤もらしい予測とそれに付随する分散によって評価される

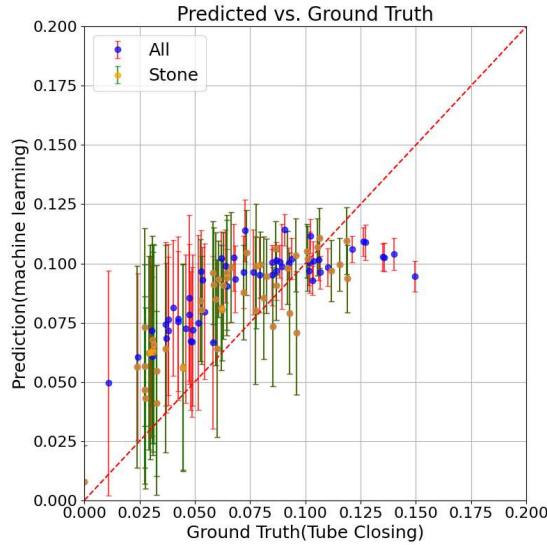


図 6.3: Caption

からであると考えられる。

一方で、実はこれら推定値はリアルタイムにおける相体積率を正しく推定しているという主張もある。実験では 5 秒間の測定を行っており、3 kHz 回の測定の間に真の物理量は明らかに変動しうる。しかし、今回の場合算出したのは平均および分散、標準偏差である。

6.1.2 問題解決の提案

より信頼性の高いモデルを構築しようとした場合に重要なのは、ハイスピードカメラで計測した画像とシミュレーションの予測値を比較することだろう。これらには人力でのアノテーションを必要とするため、現時点でのリソースでは困難である。

6.2 固気液三相流

以下は、その予測精度を評価したグラフである。6 つの目標変数を同時にプロットしてある。それらは、気相速度、液相速度、固相速度、気相体積率、液相体積率、固相体積率、である。これらに対し、決定係数 R^2 、RMSE、MAE を計算すると、以下のような結果が得られた。

これらにより、予測が可能な変数と、機械学習を以てしても予測が困難な変数がわかる。

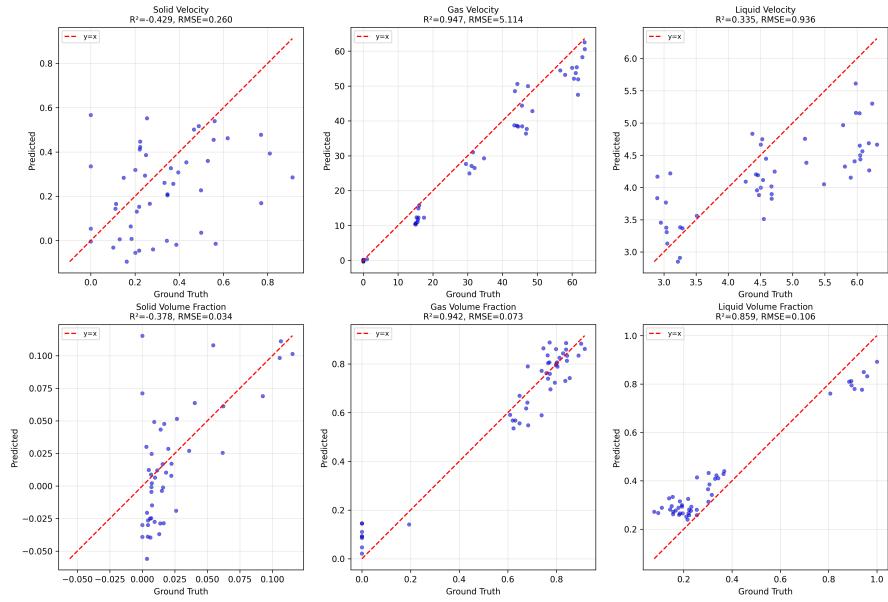


図 6.4: 縦軸が予測値を、横軸が実測値を示す。気相速度、気相体積率においては良好な予測が得られているのが視覚的にも確認できる。

variable	solid velocity	gas velocity	liquid velocity	solid volume fraction	gas volume fraction
R^2	-0.43	0.95	0.34	-0.38	0.94
RMSE	0.28	5.1	0.94	0.034	0.073
MAE	0.20	4.0	0.77	0.027	0.059

表 6.1: 決定係数 R^2 、RMSE、MAE の結果。

6.2.1 課題

固相体積率・固相見かけ流速・液相見かけ流速において課題が示された。液相に関しては、管内の流れに対し信号を得ることは難しく、また、固相の反射のような微弱な信号は、外部のノイズに埋もれてしまい検出が難しいことが予想される。これらに関しては、さらなる複雑な信号処理が必要となる。また、機械学習を使用している以上、問題設定に対して存在しない範囲のデータに対しては予測が困難となる。機械学習の一般的な性質として、外挿による予測が弱いというものが挙げられる。

6.2.2 問題解決の提案

それらのため、実際の運用をみこし、より実際の状況に近い実験を行い、計測信号を得るのが望ましい。例えば、現時点においてはガラスビーズ、水、石の固気液三相流を対象にしているが、実際の運用では泥水、石、空気の三相流になることが予想される。泥水の、超音波に対する音響インピーダンスは水のそれと異なるため信号波形は弱くなることが予想され、また、実際の系では圧力も大きく異なる。他にも、パイプの材質といった物性に関しても予測精度に影響を与えるだろう。そこで、次回以降行う実験としては、高圧力による実験条件を行い、また泥水による実験を行い計測データを得ることが望ましいだろう。そうすれば、実運用の際にも性能が大きくは低下しないであろうことが予想される。

6.3 考察

以上より、深層学習によって、特に気相のみかけ流速と相体積率を推定するモデルが得られた。これらの予測メカニズムの考察を行う。

6.3.1 判断メカニズムの考察

saliency map による、モデルの予測に対する寄与度を可視化する。以下は、最も良い精度を達成したモデルに対する saliency map を可視化したものである。気相みかけ流速の予測についての考察を行い、次に気相体積率の予測についての考察を行う。気相みかけ流速についての予測メカニズムであるが、もっとも有力なものは TDX1,TDX2 の間の統計的に類似したパターンを検出し、それらに線形な変換を施すことによって相関の高い値を出力するといったメカニズムである。これが正しければ、例えば TDX1 のみを利用して学習した場合にはその信号パターンの時間差をもとに速度を算出することができないため、精度が落ちることが考えられる。しかし、実際には以下のようない結果が得られた。これらの算出には、使用するチャンネル数のみを二つから一つに減らし、その他のハイパーパラメータ最適化アルゴリズムに関しては変更を加えていない。これらの結果から、気相みかけ流速の予測については、TDX1,TDX2 の間の統計的に類似したパターンを検出し、それらに線形な変換を施すことによって相関の高い値を出力するといったメカニズムは考えにくいということが考えられる。

6.3.2 管径に依存しないモデルの構築

管径が異なるモデルにおける予測精度を評価できているわけではなく、評価のためのデータセットも以前として準備段階にあるというものが現状である。産総研でのデータセットに関しては、管とトランステューサの距離が近すぎるために信号パターンが大きく異なってしま

42 第6章 学習結果

う。令和7年に取得したデータセットに関しては汎化が可能である可能性がある。

第 7 章

結論

固気液三相流において、超音波信号を入力、締切法によって計測した値を目標値として深層学習モデルを構築した。今回開発したモデルは、気相みかけ流速、気相体積率の予測において決定係数 0.9 以上を達成した。また、固液二相においては数値計算による信号波形を学習したが、実機に対する予測としても比較的良い精度を達成し、その判断根拠としては向かい側の管壁からの反射波の部分に着目している結果が得られた。

謝辞

参考文献

- [1] 桑木裕基. 南鳥島周辺海域における海底資源評価のための海底地形及び反射散乱強度解析. 日本航海学会誌 NAVIGATION, Vol. 200, pp. 57–57, 2017.
- [2] 清水和弥, 高木周. 200 m 立型水槽を用いたエアリフト実験について. 混相流, Vol. 36, No. 3, pp. 320–328, 2022.
- [3] 片岡勲. 気液二相流のモデリングと基礎式・構成式. 混相流, Vol. 15, No. 1, pp. 4–13, 2001.
- [4] Jefferson Dos Santos Ambrosio, Marco Jose da Silva, and André Eugênio Lazzaretti. A deep learning-based approach for two-phase flow pattern classification using void fraction time series analysis. *IEEE Access*, Vol. 13, pp. 11778–11791, 2025.
- [5] Christopher M Bishop and Gwilym D James. Analysis of multiphase flows using dual-energy gamma densitometry and neural networks. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, Vol. 327, No. 2-3, pp. 580–593, 1993.
- [6] WL Salgado, RSF Dam, and CM Salgado. Optimization of a flow regime identification system and prediction of volume fractions in three-phase systems using gamma-rays and artificial neural network. *Applied Radiation and Isotopes*, Vol. 169, p. 109552, 2021.
- [7] MMF Figueiredo, JL Goncalves, AMV Nakashima, AMF Fileti, and RDM Carvalho. The use of an ultrasonic technique and neural networks for identification of the flow pattern and measurement of the gas volume fraction in multiphase flows. *Experimental Thermal and Fluid Science*, Vol. 70, pp. 29–50, 2016.
- [8] Maurício de Melo Freire Figueiredo, Felipe de Castro Teixeira Carvalho, Ana Maria Frattini Fileti, and Alberto Luiz Serpa. Flow pattern classification in water-air vertical flows using a single ultrasonic transducer. *Experimental Thermal and Fluid Science*, Vol. 119, p. 110189, 2020.

- [9] Hyun Jin Park, Dongik Yoon, Shintaro Akasaka, Yuji Tasaka, and Yuichi Murai. Gas volume estimation in a vertical pipe flow considering the bubble size obtained from an ultrasonic velocity vector profiler. *Experiments in Fluids*, Vol. 63, No. 8, p. 130, 2022.
- [10] 小野寺直幸, 青木尊之. Gpu を用いた固体粒子を含む固気液三相流の大規模シミュレーション. 混相流, Vol. 27, No. 5, pp. 607–613, 2014.
- [11] Christopher M. Bishop and Hugh Bishop. *Deep Learning: Foundations and Concepts*. Springer, 2024.
- [12] Ramprasaath R. Selvaraju, Michael Cogswell, Abhishek Das, Ramakrishna Vedantam, Devi Parikh, and Dhruv Batra. Grad-cam: Visual explanations from deep networks via gradient-based localization. *International Journal of Computer Vision*, Vol. 128, No. 2, p. 336–359, October 2019.
- [13] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [14] Haochen HUANG, Daisuke KONO, and Masahiro TOYOURA. Vision based two-dimensional measurement of machine tool motion trajectory. *Journal of Advanced Mechanical Design, Systems, and Manufacturing*, Vol. 18, No. 6, pp. JAMDSM0080–JAMDSM0080, 2024.
- [15] 忠司坂口, 弘紀井尻, 正之煙崎, 秀明赤対. 鉛直円管内気液二相気泡流の気相体積率分布に関する一考察. 混相流, Vol. 10, No. 4, pp. 389–396, 1996.
- [16] G.K. Batchelor. *An Introduction to Fluid Dynamics*. Cambridge mathematical library. Cambridge University Press, 2000.
- [17] 村井祐一, 田坂裕司, 朴玄珍, 高野慧, 正信聰太郎. 超音波によるエアリフト管内の混相流の計測. 混相流, Vol. 36, No. 3, pp. 329–335, 2022.
- [18] Ross Girshick, Jeff Donahue, Trevor Darrell, and Jitendra Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 580–587, 2014.
- [19] Vikas Sheoran, Shreyansh Joshi, and Tanisha R Bhayani. Age and gender prediction using deep cnns and transfer learning. In *International Conference on Computer Vision and Image Processing*, pp. 293–304. Springer, 2020.
- [20] Guodong Guo, Yun Fu, Charles R Dyer, and Thomas S Huang. A probabilistic fusion approach to human age prediction. In *2008 IEEE computer society conference on computer vision and pattern recognition workshops*, pp. 1–6. IEEE, 2008.

- [21] Zakariya Ba Alawi. A comparative survey of pytorch vs tensorflow for deep learning: Usability, performance, and deployment trade-offs, 2025.
- [22] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.
- [23] Hao Li, Zheng Xu, Gavin Taylor, Christoph Studer, and Tom Goldstein. Visualizing the loss landscape of neural nets. *Advances in neural information processing systems*, Vol. 31, , 2018.

付録 A

付録

機械学習は統計的な手法であり、アルゴリズムの設計にもその性能評価にもいくつかの数学的準備を必要とする。ここでは、用いた議論や論拠の補足を行う。

A.1 指標

分類・回帰の性能評価に関する議論を行う。分類モデルに関しては精度・再現率・F 値といった数々の指標が良く議論されている一方で、回帰タスクにおいては十分に行われていないようである。ここでは、その性能指標について、今回 RMSE を MAE よりも好むかの理由について述べる。

そもそも、今回は固相体積率という連続値をとる量を推定する目的で研究が行われてきた。その理由は、構成方程式の精度を検証するためであった。誤差が生じる状況を大きく二分するとすれば、次の二つのケースが考えられる。

1. 全体的に中程度の誤差が出て、大きな誤差を取るもののが極めて少ない
2. 全体的に小程度の誤差が出て、一部のみ大きな誤差を取るもののが存在する。

このうち、精度を検証する目的では全体的な中程度の誤差は、一部の大きな誤差よりも優先される。MAE ではその誤差に対して線形な損失を割り当てるのに対し、MSE ではその誤差の二乗の損失を割り当てる。それゆえ、L1Loss (MAE) よりも L2Loss(MSE) のほうが望ましい。さらに言えば、ある程度の誤差が許容されるのであればより高次の Loss を用いるのが望ましい。MAE を利用しない理由はこれである。

A.2 物性値

物性値に関しては、現在に至るまでの数々の実験から再現可能な量が測定されてある。まず初めに、計算系において物性値を以下のように設定した。いくつかの書類には 25A 塩ビ

substance	Acoustic impedance	density	sound velocity
air	0.00043	1.3	330
water	1.5	1000	1500
glass	18.9	2200	5300

表 A.1: acoustic impedance used in the experiment

管を利用しているという記載があり、研究員の共通認識であった。しかし、予備試験の結果により、音速が 2790 m/s 程度であることが判明した。このことから、塩ビ管ではなくアクリルではないかという疑念が存在し、実験設備の構築を担当する方に確認を取ったところ、アクリル管を利用していることが判明した。このことから、音速を 2790 m/s として計算を行った。今後、同様のアプローチを採用する場合には、厚さ測定及び材質の音速の再推定結果に基づいて検証することが望ましい。なお、材質の音速推定については、以下のような方法で行った。

1. 信号をヒルベルト変換する
2. 管内壁、外壁でピークを取る時刻をそれぞれ取得し、比較する
3. 厚さを時間差で除算することによって音速を推定する。

「信号をヒルベルト変換する」について解説する。実機試験を行った場合の 1 パルスの測定結果を以下に示す。

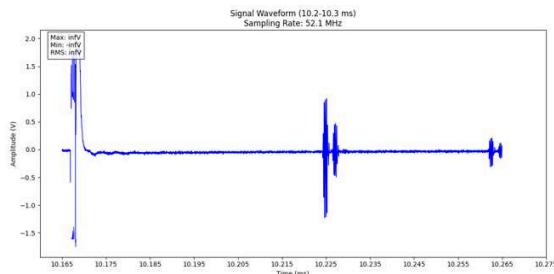


図 A.1: 実機試験を行った場合の 1 パルスの測定結果。

50 付録 A 付録

これらのうち、見えやすい最初のピークと、その次のピークをさらに拡大して表示する。この際、ヒルベルト変換を行い、包絡線を取得してある。

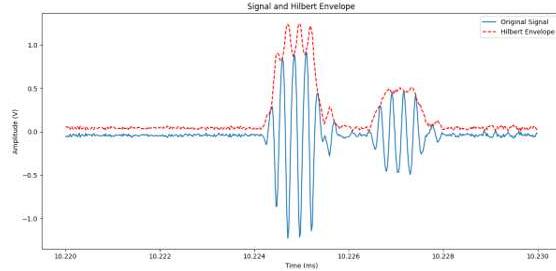


図 A.2: パイプの外壁、内壁を拡大した画像

ここで、形状が綺麗に一つのピークを持たず、何回かのピークがあるのが見て取れる。理想的には、シミュレーションの結果のように、A.3 のようになる。ここで、ピークが複数回

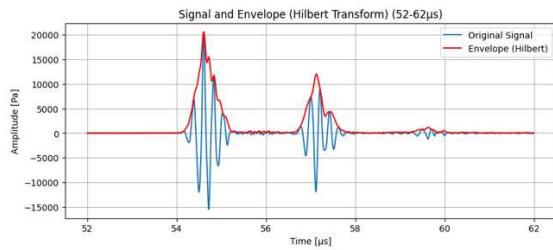


図 A.3: シミュレーションの信号波形の、管壁付近の拡大。ヒルベルト変換後のピークが唯一である。

出ている理由は、実機のトランステューサの機器依存の現象である。しかし、内壁、外壁それぞれのピークの間の時間差には対応関係が存在する。それらを測定すると、時間差は $2.15 \pm 0.019 \mu\text{s}$ である。このことから、音速を 2790 m/s と推定することができる。

なお、塩ビ管の音速は、 2300 m/s 程度であり、あまりに誤差が大きい。パイプの厚みが 3 mm ではなく、 2.5 mm であったならば矛盾はないが、数値計算の上ではこれらを明確に確認する必要がある。